

Redes Neurais Convolucionais

Fernando Humberto de Almeida Moraes Neto

19 de janeiro de 2022

Sumário

- 1 Introdução
- 2 Arquitetura Geral
- 3 Treinamento
- 4 Técnicas que podem ser utilizadas para melhora de predição das Redes Neurais Convolucionais
 - Dropout
 - Aumento de dados
 - Transferência de Aprendizado
 - *Ensemble*
- 5 Aplicação
- 6 Considerações Finais
- 7 Referências Bibliográficas

Introdução

- Redes Neurais Convolucionais (do inglês *Convolutional Neural Network* CNN) são técnicas utilizadas na análise de imagem.


Introdução

ImageNet

- Contém mais de 14 milhões de imagens.
- Desafio de reconhecimento visual de grande escala do *ImageNet* (do inglês *ImageNet Large Scale Visual Recognition Competition* (ILSVRC)).

Introdução

Figura 1: Taxa de erro (%) dos modelos propostos pelos vencedores do Desafio de Reconhecimento Visual de Larga Escala *ImageNet* (ILSVRC) de 2011 a 2016.



Introdução

- Um tipo de arquitetura de aprendizado profundo que possui a operação de convolução em pelo menos uma camada (GOODFELLOW; BENGIO; COURVILLE, 2016).

- Essas redes são modeladas para processar dados em formato de múltiplos vetores (NETO; MENEZES et al., 2018).

Introdução

- Um tipo de arquitetura de aprendizado profundo que possui a operação de convolução em pelo menos uma camada (GOODFELLOW; BENGIO; COURVILLE, 2016).

- Essas redes são modeladas para processar dados em formato de múltiplos vetores (NETO; MENEZES et al., 2018).

Introdução

As CNN's

- Capacidade de extrair características relevantes através dos *kernels*.
- Dependem de um menor número de parâmetros de ajustes do que as redes totalmente conectadas com o mesmo número de camadas ocultas (ARAÚJO et al., 2017).

Introdução

As CNN's

- Capacidade de extrair características relevantes através dos *kernels*.
- Dependem de um menor número de parâmetros de ajustes do que as redes totalmente conectadas com o mesmo número de camadas ocultas (ARAÚJO et al., 2017).

Introdução

Trabalhos que utilizaram CNN's

- Freitas (2018): desenvolveu um modelo de CNN para classificação de cáries dentárias através de radiografias;
- Mende (2018): construiu três modelos de CNN's para segmentar estas imagens de modo a auxiliar os profissionais que trabalham com ultrasson de lesões de mama;
- Ferreira (2018): por meio de imagens dermatoscópicas, utilizou CNN's para segmentar estas imagens com o objetivo de auxiliar os profissionais para uma melhor identificação deste tipo de câncer;
- Neto, Mendes (2018): desenvolveram uma CNN para reconhecer sinais da Língua de Sinais Argentina.

Sumário

- 1 Introdução
- 2 Arquitetura Geral**
- 3 Treinamento
- 4 Técnicas que podem ser utilizadas para melhora de predição das Redes Neurais Convolucionais
 - Dropout
 - Aumento de dados
 - Transferência de Aprendizado
 - *Ensemble*
- 5 Aplicação
- 6 Considerações Finais
- 7 Referências Bibliográficas

Arquitetura Geral




Figura 2: Arquitetura geral de uma CNN.

Operação de Convolução

- As saídas do processo de convolução são organizadas em mapas de recursos, e estão conectadas a uma parte da camada anterior por meio dos filtros.

Padding e o stride

- O *stride* (ou tamanho do passo) denota o número de *pixels* pelos quais o filtro se move após cada operação.
- O *padding* insere simetricamente novos *pixels* ao redor da imagem de entrada.

Operação de Convolução

- As saídas do processo de convolução são organizadas em mapas de recursos, e estão conectadas a uma parte da camada anterior por meio dos filtros.

Padding e o stride

- O *stride* (ou tamanho do passo) denota o número de *pixels* pelos quais o filtro se move após cada operação.
- O *padding* insere simetricamente novos *pixels* ao redor da imagem de entrada.

Operação de Convolução

- As saídas do processo de convolução são organizadas em mapas de recursos, e estão conectadas a uma parte da camada anterior por meio dos filtros.

Padding e o stride

- O *stride* (ou tamanho do passo) denota o número de *pixels* pelos quais o filtro se move após cada operação.
- O *padding* insere simetricamente novos *pixels* ao redor da imagem de entrada.

Convolução

- Considerando um *kernel*/filtro de tamanho bidimensional K e uma imagem de entrada X pode ser descrito por:

$$S(i, j) = (K * X)(i, j) = \sum_m \sum_n X(m, n) K(i - m, j - n).$$

Convolução

- Considerando um *kernel*/filtro de tamanho bidimensional K e uma imagem de entrada X pode ser descrito por:

$$S(i, j) = (K * X)(i, j) = \sum_m \sum_n X(m, n) K(i - m, j - n).$$

Operação de Convolução

Pooling

- Reduzir a resolução dos mapas de recursos.

- Os tipos mais comuns são:

- *pooling* máximo.
- *pooling* médio.

Pooling

- Reduzir a resolução dos mapas de recursos.

- Os tipos mais comuns são:

- *pooling* máximo.
- *pooling* médio.


Pooling

- Reduzir a resolução dos mapas de recursos.

- Os tipos mais comuns são:

- *pooling* máximo.
- *pooling* médio.

Figura 3: Exemplo de *pooling* máximo e médio.




Fonte: (YANI et al., 2019).

Achatamento

- Leva as características extraídas da imagem a uma rede neural artificial, na qual, todas as suas unidades estão totalmente conectadas com a camada anterior (FERREIRA, 2017).

Achatamento

Figura 4: Exemplo do processo de achatamento.



Sumário

- 1 Introdução
- 2 Arquitetura Geral
- 3 Treinamento**
- 4 Técnicas que podem ser utilizadas para melhora de predição das Redes Neurais Convolucionais
 - Dropout
 - Aumento de dados
 - Transferência de Aprendizado
 - *Ensemble*
- 5 Aplicação
- 6 Considerações Finais
- 7 Referências Bibliográficas

Treinamento das CNN's

- O principal objetivo do treinamento de uma CNN é fazer com que a aplicação de um conjunto de entradas produza um conjunto de saídas desejadas ou, no mínimo, um conjunto de saídas consistentes. Esse treinamento consiste em determinar os pesos adequados para seus parâmetros de forma a minimizar erros que a rede possa cometer.

- *Backpropagation: Forward e Backward.*

- Gradiente Descendente: Gradiente Descendente, Estocástico e com Momentos.

- Ajustar os pesos de forma a diminuir a diferença entre a saída esperada e a saída obtida.

- Esta diferença é medida através de uma função de perda.
 - *Softmax Cross Entropy* e *Sigmoid Cross Entropy*;
 - Erro Quadrático Médio.

- *Backpropagation: Forward e Backward.*
- Gradiente Descendente: Gradiente Descendente, Estocástico e com Momentos.

- Ajustar os pesos de forma a diminuir a diferença entre a saída esperada e a saída obtida.

- Esta diferença é medida através de uma função de perda.
 - *Softmax Cross Entropy e Sigmoid Cross Entropy;*
 - Erro Quadrático Médio.

- *Backpropagation: Forward e Backward.*
- Gradiente Descendente: Gradiente Descendente, Estocástico e com Momentos.

- Ajustar os pesos de forma a diminuir a diferença entre a saída esperada e a saída obtida.

- Esta diferença é medida através de uma função de perda.
 - *Softmax Cross Entropy e Sigmoid Cross Entropy;*
 - Erro Quadrático Médio.

- *Backpropagation: Forward e Backward.*
- Gradiente Descendente: Gradiente Descendente, Estocástico e com Momentos.

- Ajustar os pesos de forma a diminuir a diferença entre a saída esperada e a saída obtida.

- Esta diferença é medida através de uma função de perda.
 - *Softmax Cross Entropy e Sigmoid Cross Entropy;*
 - Erro Quadrático Médio.

- *Backpropagation: Forward e Backward.*
- Gradiente Descendente: Gradiente Descendente, Estocástico e com Momentos.

- Ajustar os pesos de forma a diminuir a diferença entre a saída esperada e a saída obtida.

- Esta diferença é medida através de uma função de perda.
 - *Softmax Cross Entropy* e *Sigmoid Cross Entropy*;
 - Erro Quadrático Médio.

Sumário

- 1 Introdução
- 2 Arquitetura Geral
- 3 Treinamento
- 4 Técnicas que podem ser utilizadas para melhora de predição das Redes Neurais Convolucionais
 - Dropout
 - Aumento de dados
 - Transferência de Aprendizado
 - *Ensemble*
- 5 Aplicação
- 6 Considerações Finais
- 7 Referências Bibliográficas

Dropout


- Para evitar que ocorra o *overfitting*.

- O método *dropout* consiste em retirar unidades com uma certa probabilidade p da rede, e manter unidades com probabilidade $(1 - p)$.

Dropout

- Para evitar que ocorra o *overfitting*.
- O método *dropout* consiste em retirar unidades com uma certa probabilidade p da rede, e manter unidades com probabilidade $(1 - p)$.

Figura 5: Exemplo de uma rede neural sem *dropout* (a) e com *dropout* (b), em que na última linha tem-se um *dropout* de 40%, pois foram retirados 2 neurônios dos 5.



Fonte: (SRIVASTAVA et al., 2014).

Aumento de dados

- Para obter uma boa generalização do modelo.

Figura 6: Imagem a ser aumentada.



Figura 7: Transformações referentes a imagem da Figura 6.

Baseado em
Geometria



Baseado em
cores



Baseado em
Ruído



Transferência de Aprendizado

- O processo de usar modelos pré-treinados.


- Modificar a última camada totalmente conectada da rede.

Transferência de Aprendizado

- O processo de usar modelos pré-treinados.

- Modificar a última camada totalmente conectada da rede.

Figura 8: Exemplo de Transferência de Aprendizado.



Ensemble

- Um *ensemble* é um modelo constituído por um conjunto de outros modelos, chamados de componentes, cujas decisões são combinadas de alguma forma, para predizer novas instâncias (FERREIRA, 2012).

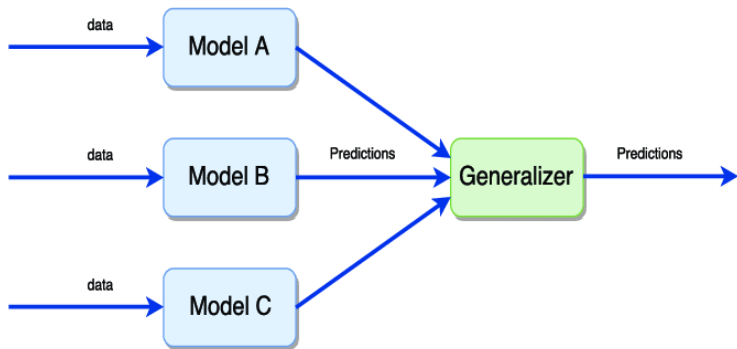



Figura 9: Exemplo de uma combinação de modelos.

Figura 10: Exemplo da moda como uma combinação de modelos.



Sumário

- 1 Introdução
- 2 Arquitetura Geral
- 3 Treinamento
- 4 Técnicas que podem ser utilizadas para melhora de predição das Redes Neurais Convolucionais
 - Dropout
 - Aumento de dados
 - Transferência de Aprendizado
 - *Ensemble*
- 5 Aplicação**
- 6 Considerações Finais
- 7 Referências Bibliográficas

Brain Tumor MRI

- Hospedada na plataforma *Kaggle*.

- Contém 253 imagens de ressonância magnética do cérebro, sendo 155 imagens que contém tumor e 98 não possuem.

Brain Tumor MRI

- Hospedada na plataforma *Kaggle*.

- Contém 253 imagens de ressonância magnética do cérebro, sendo 155 imagens que contém tumor e 98 não possuem.

Imagens da base de dados Brain Tumor MRI




Figura 11: Imagens da base de dados sem tumor.




Figura 12: Imagens da base de dados com tumor.

Pré-processamento




Figura 13: Pré-processamento, onde (a) é a imagem original, (b) é a imagem original cortada e (c) é a imagem final através da equalização do histograma.

Arquitetura da CNN utilizada




Figura 14: Esqueleto da CNN elaborada com suas respectivas dimensões de saída.

Arquitetura da CNN utilizada




Figura 15: Arquitetura da VGG16.

Função de ligação

- ReLU;
- Sigmoid.

Método de validação

- *Data splitting.*
 - 70% para treinamento;
 - 15% para teste;
 - 15% na validação.

Função de perda

- Entropia Cruzada.
 - *Adadelta.*

Função de ligação

- ReLU;
- Sigmoid.

Método de validação

- *Data splitting.*
 - 70% para treinamento;
 - 15% para teste;
 - 15% na validação.

Função de perda

- Entropia Cruzada.
 - *Adadelta.*

Função de ligação

- ReLU;
- Sigmoid.

Método de validação

- *Data splitting.*
 - 70% para treinamento;
 - 15% para teste;
 - 15% na validação.

Função de perda

- Entropia Cruzada.
 - *Adadelta.*

Função de ligação

- ReLU;
- Sigmoid.

Método de validação

- *Data splitting.*
 - 70% para treinamento;
 - 15% para teste;
 - 15% na validação.

Função de perda

- Entropia Cruzada.
 - *Adadelta.*

Resultados

Tabela 1: Matriz de confusão do modelo proposto.

Valor Predito	Valor Verdadeiro	
	Sem tumor	Com tumor
	Sem tumor	8
Com tumor	2	27

Tabela 2: Medidas de desempenho baseadas na matriz de confusão.

Medidas	Valores (%)
Acurácia	92,11
Recall	88,89
Precisão	80,00
Especificidade	96,42

Resultados

- Apesar de ter uma boa ACC, esta pode estar sendo influenciada pelas classes desbalanceadas.
 - Aumento de dados no conjunto de treino.

Resultados

- Apesar de ter uma boa ACC, esta pode estar sendo influenciada pelas classes desbalanceadas.
 - Aumento de dados no conjunto de treino.

Sumário

- 1 Introdução
- 2 Arquitetura Geral
- 3 Treinamento
- 4 Técnicas que podem ser utilizadas para melhora de predição das Redes Neurais Convolucionais
 - Dropout
 - Aumento de dados
 - Transferência de Aprendizado
 - *Ensemble*
- 5 Aplicação
- 6 Considerações Finais**
- 7 Referências Bibliográficas

Considerações Finais

Redes Neurais Convolucionais

- Avanço científico em diversas áreas do conhecimento;
- Quantidade menor de parâmetros;
- Redução da memória computacional utilizada.

Considerações Finais

Redes Neurais Convolucionais

- Avanço científico em diversas áreas do conhecimento;
- Quantidade menor de parâmetros;
- Redução da memória computacional utilizada.

Considerações Finais

Redes Neurais Convolucionais

- Avanço científico em diversas áreas do conhecimento;
- Quantidade menor de parâmetros;
- Redução da memória computacional utilizada.

Sumário

- 1 Introdução
- 2 Arquitetura Geral
- 3 Treinamento
- 4 Técnicas que podem ser utilizadas para melhora de predição das Redes Neurais Convolucionais
 - Dropout
 - Aumento de dados
 - Transferência de Aprendizado
 - *Ensemble*
- 5 Aplicação
- 6 Considerações Finais
- 7 Referências Bibliográficas**

Referências Bibliográficas

- ARAUJO, F. H. et al. Redes neurais convolucionais com tensorflow: Teoria e prática. *SOCIEDADE BRASILEIRA DE COMPUTAÇÃO. III Escola Regional de Informática do Piauí. Livro Anais-Artigos e Minicursos*, Sociedade Brasileira de Computação, v.1, p. 382–406, 2017.
- FERREIRA, E. J. *Método baseado em rotação e projeção otimizadas para a construção de ensembles de modelos*. Tese (Doutorado) — Universidade de São Paulo, 2012.
- FERREIRA, A. E. T. *Estimação do ângulo de direção por vídeo para veículos autônomos utilizando redes neurais convolucionais multicanais*. 2017.

Referências Bibliográficas

- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. Deep Learning. [S.l.]: MIT Press, 2016.<<http://www.deeplearningbook.org>>.
- NETO, R.; MENEZES, G. et al. Reconhecimento de língua de sinais baseado em redes neurais convolucionais 3d. Universidade Federal do Maranhão, 2018.

Redes Neurais Convolucionais

Fernando Humberto de Almeida Moraes Neto

19 de janeiro de 2022